



Final Report

Intern Name	Dimas Anggiat	Topic	Arm Edge AI Wearable - Arrhythmia Atrial Fibrillation Detection
Supervisor	Faudzan	Status	Final
Target Hardware	Grove Vision AI V2 (Cortex-M55 + Ethos-U55)		

1. Overview

Proyek ini mengimplementasikan sistem deteksi Atrial Fibrilasi (AF) secara real-time berbasis sinyal photoplethysmography (PPG) menggunakan sensor MAX30102. Seluruh sistem dijalankan pada target perangkat keras Grove Vision AI V2 yang mengintegrasikan prosesor ARM Cortex-M55 dan akselerator Ethos-U55 NPU. Pemrosesan sinyal mentah dilakukan langsung pada firmware C, lalu dilanjutkan dengan eksekusi model 1D Convolutional Neural Network (1D-CNN) terkuantisasi INT8. Tujuan utama dari arsitektur ini adalah mengeksekusi inferensi AI sepenuhnya di NPU guna menekan latensi dan konsumsi daya secara drastis pada perangkat wearable.

2. Background

Atrial Fibrilasi (AF) merupakan jenis aritmia jantung yang paling sering ditemui dalam dunia kesehatan dan menjadi pemicu utama terjadinya stroke iskemik serta gagal jantung. Tantangan terbesar dalam diagnosis AF terletak pada sifat episodenya yang sering muncul secara mendadak dan hilang-timbul (*paroxysmal*), bahkan sering kali berlangsung tanpa gejala fisik yang jelas yang disadari oleh pasien. Karena kemunculannya yang tidak dapat diprediksi, perekaman sinyal jantung dalam durasi singkat kerap kali gagal menangkap keberadaan aritmia ini. Oleh karena itu, pemantauan aktivitas jantung jangka panjang (*long-term continuous monitoring*) menjadi sangat krusial untuk mendeteksi episode AF secara dini sebelum berkembang menjadi komplikasi kesehatan yang serius.

Meskipun elektrokardiogram (ECG) seperti pemantau Holter atau patch ECG merupakan *gold standard* dalam diagnosis kelistrikan jantung, penggunaannya untuk jangka panjang menghadapi kendala kenyamanan dan kedisiplinan pemakaian oleh pasien. Penggunaan elektroda perekat pada kulit dalam kurun waktu sehari-hari sering kali menyebabkan iritasi, rasa tidak nyaman, serta membutuhkan biaya yang relatif mahal. Sebagai alternatif, teknologi *photoplethysmography* (PPG) berbasis optik yang tertanam pada perangkat wearable pergelangan tangan atau jari menjadi alternatif pemantauan tanpa melukai kulit yang jauh lebih praktis dan ekonomis. Sinyal PPG mengukur perubahan volume darah pada pembuluh darah perifer akibat denyut jantung, sehingga memungkinkan pengumpulan data secara terus-menerus dalam aktivitas sehari-hari tanpa mengganggu kenyamanan pengguna.

Secara standar medis dan mengacu pada *benchmarks* dalam literatur ilmiah, sistem deteksi AF berbasis PPG dituntut untuk memiliki performa yang tinggi, dengan acuan tingkat *sensitivity* dan *specificity* di atas 90%. *Sensitivity* yang tinggi diperlukan agar sistem tidak melewatkan episode AF tersembunyi, sementara *specificity* yang tinggi penting untuk menekan angka *false alarm* yang dapat memicu kecemasan tidak perlu pada pasien. Namun, pengolahan sinyal PPG secara terus-menerus pada perangkat wearable berukuran kecil menghadapi batasan berupa keterbatasan kapasitas baterai serta konsumsi daya.

Untuk memenuhi standar tersebut tanpa mengorbankan daya tahan baterai, pemrosesan berbasis kecerdasan buatan (*AI inference*) wajib dilakukan secara lokal di dalam perangkat (*on-device*). Jika pemrosesan dibebankan pada prosesor utama (CPU), kalkulasi perkalian matriks dari model Deep Learning akan menyebabkan konsumsi daya melonjak tinggi dan memicu panas berlebih. Oleh karena itu, arsitektur sistem dalam proyek ini dirancang dengan

memindahkan seluruh beban komputasi model AI ke *Neural Processing Unit* (NPU). Akselerasi berbasis NPU ini memungkinkan eksekusi inferensi dengan latensi rendah dan konsumsi energi yang sangat efisien, sehingga pemantauan AF secara real-time dapat direalisasikan secara optimal pada perangkat edge.

3. Dataset & Preprocessing

Dataset yang digunakan dalam proyek ini berasal dari repositori publik Zenodo. Dataset ini memuat rekaman sinyal elektrokardiogram (ECG) dan *photoplethysmography* (PPG) dari pergelangan tangan yang dikumpulkan secara bersamaan pada 45 pasien terduga Atrial Fibrilasi. Sinyal PPG diukur pada frekuensi *sampling* 100 Hz menggunakan sensor optik LED hijau, sedangkan sinyal ECG referensi dicatat pada frekuensi 500 Hz dengan anotasi episode AF berbasis *beat-to-beat* oleh tim spesialis medis. Karakteristik ini membuat dataset Zenodo sangat representatif untuk melatih dan menguji model klasifikasi berbasis PPG secara objektif.

Sinyal PPG kontinu dipotong menjadi segmen-segmen waktu (*windowing*) berdurasi 10 detik, yang menghasilkan 1000 sampel data per *window*. Setiap segmen diberi label biner, yaitu kelas 0 untuk *non-AF* dan kelas 1 untuk *AF*, berdasarkan persentase kemunculan denyut AF dari anotasi ECG. Pada proses *training* di Python, diterapkan *fine-step windowing* dengan *overlap* sebesar 75% khusus pada sinyal kelas AF sebagai bentuk augmentasi data untuk memperbanyak variasi sampel. Sementara itu, sinyal kelas *non-AF* dan seluruh data uji tetap menggunakan pemotongan normal tanpa *overlap*. Untuk mencegah *data leakage* antar-pasien, pembagian data latih dan data uji dilakukan secara khusus berbasis subjek (*GroupShuffleSplit*). Selain itu, ketidakseimbangan jumlah sampel antar-kelas (*class imbalance*) ditangani saat proses *training* menggunakan metode pembobotan kelas (*class weight*) yang disesuaikan secara proporsional.

Proses pembersihan sinyal dan ekstraksi data dirancang dengan memperhatikan spesifikasi perangkat yang terbatas. Pada tahap *training* di Python, sinyal PPG difilter menggunakan *bandpass filter* Butterworth orde-4 pada rentang frekuensi 0.5-8.0 Hz, kemudian dinormalisasi menggunakan *Z-score* per *window*. Untuk implementasi *on-device* pada *firmware* C, algoritma proses filter direalisasikan secara *real-time* menggunakan empat tahapan *biquad bandpass filter* terkaskade dengan koefisien yang disesuaikan untuk frekuensi *sampling* 100 Hz. Sampel sinyal mentah yang dibaca dari sensor MAX30102 difilter satu per satu dan disimpan ke dalam *circular buffer* berukuran 1000 sampel. Setelah *buffer* terisi penuh, mikrokontroler akan langsung menghitung nilai rata-rata dan standar deviasi untuk normalisasi *Z-score*, lalu mengonversi nilainya ke format INT8 berdasarkan parameter skala (*scale*) dan titik nol (*zero-point*) dari tensor masukan model sebelum diserahkan ke NPU untuk proses inferensi.

4. Model

Model yang dikembangkan berbasis arsitektur 1D *Convolutional Neural Network* (1D-CNN) yang dirancang khusus untuk mengekstrak pola dari sinyal deret waktu. Bentuk *input* model berupa matriks tunggal berukuran (1000, 1), yang merepresentasikan 1000 sampel sinyal PPG dalam satu segmen *window* berdurasi 10 detik. Susunan arsitektur (*layer-by-layer*) terdiri dari dua blok konvolusi untuk ekstraksi fitur dan satu blok *dense* untuk klasifikasi. Blok pertama dimulai dengan lapisan Conv1D berkapasitas 64 filter (ukuran kernel 3, aktivasi ReLU), yang dilanjutkan dengan lapisan MaxPooling1D berukuran 2. Blok kedua mengaplikasikan lapisan Conv1D dengan 128 filter (ukuran kernel 3, aktivasi ReLU) dan diikuti oleh lapisan MaxPooling1D berukuran 2. Output dari proses konvolusi kemudian melewati lapisan *flatten* sebelum masuk ke lapisan *Dense* berkapasitas 128 unit dengan aktivasi ReLU. Lapisan terakhir berupa *Dense* dengan 2 unit beraktivasi *softmax* untuk memetakan hasil prediksi ke dalam kelas non-AF dan AF. Berdasarkan kalkulasi susunan lapisan tersebut, model ini memiliki total parameter sebesar 4.088.578 parameter.

Proses pelatihan model dijalankan menggunakan kerangka kerja TensorFlow. Pengoptimalan bobot model menggunakan *optimizer* Adam dengan *loss function* *sparse categorical crossentropy*. *Training* dikonfigurasi untuk berjalan hingga maksimal 30 epoch dengan ukuran batch sebesar 32 sampel per iterasi. Untuk mencegah terjadinya overfitting serta menjaga generalisasi model terhadap data baru, diterapkan beberapa teknik regularisasi. Lapisan *Dropout* sebesar 50% dipasang di antara lapisan *Dense*. Selain itu, diterapkan mekanisme *callback* berupa *EarlyStopping* dengan *patience* 5 *epoch* untuk menghentikan *training* secara otomatis saat nilai *validation loss* berhenti membaik, serta penggunaan *ReduceLROnPlateau* untuk menurunkan *learning rate* jika proses konvergensi melambat. Pembobotan kelas (*class weight*) juga dihitung secara otomatis untuk menyeimbangkan pengaruh sampel kelas AF dan non-AF selama pembaruan bobot model.

5. Results

Evaluasi performa model dilakukan menggunakan 158.221 segmen data uji, yang terdiri dari 146.273 segmen non-AF dan 11.948 segmen AF. Pengujian ini bertujuan untuk menilai performa klasifikasi secara mendetail sekaligus membandingkan model baseline floating-point (.keras) dengan model terkuantisasi INT8 (.tflite). Ringkasan metrik performa untuk tiap kelas beserta perbandingan kedua model pada threshold optimal masing-masing diberikan pada tabel di bawah ini.

Tabel 1. Metrik Performa untuk Setiap Kelas Kedua Model Baseline dan Terkuantisasi

Model	Kelas	Precision	Recall	F1-Score	Accuracy
Baseline (.keras)	non-AF	0.95	0.70	0.81	0.69
	AF	0.14	0.57	0.22	
Quantized (.tflite INT8)	non -AF	0.95	0.70	0.80	0.68
	AF	0.12	0.51	0.20	

Berdasarkan perbandingan pada tabel di atas, model baseline (.keras) menghasilkan akurasi keseluruhan sebesar 0.69 dengan F1-score kelas AF sebesar 0.22. Setelah proses kuantisasi ke format INT8 (.tflite), performa model hanya mengalami penurunan tipis, yaitu akurasi menjadi 0.68 dan F1-score kelas AF menjadi 0.20. Hal ini membuktikan bahwa penyusutan format dari floating-point ke int 8-bit tidak merusak kemampuan ekstraksi fitur model.

Untuk menganalisis distribusi prediksi secara presisi, hasil klasifikasi dari kedua model dipetakan ke dalam confusion matrix pada tabel berikut.

Tabel 2. Confusion Matrix

		Prediksi non-AF	Prediksi AF
Baseline (.keras)	Aktual non-AF	102.296 (TN)	43.977 (FP)
	Aktual AF	5.080 (FN)	6.868 (TP)
Quantized (.tflite INT8)	Aktual non-AF	102.132 (TN)	44.141 (FP)
	Aktual AF	5.797 (FN)	6.151 (TP)

Berdasarkan tabel *confusion matrix* tersebut, model *baseline* berhasil mengidentifikasi 102.296 sampel *True Negative* (TN) dan 6.868 sampel *True Positive* (TP), tetapi menghasilkan 43.977 sampel *False Positive* (FP) serta 5.080 sampel *False Negative* (FN). Pada model terkuantisasi INT8, pergeseran angka terjadi secara wajar dengan perolehan 102.132 sampel TN, 6.151 sampel TP, 44.141 sampel FP, dan 5.797 sampel FN.

Analisis terhadap *failure cases* menunjukkan bahwa kendala utama model terletak pada tingginya angka *False Positive*, di mana sekitar 44 ribu segmen *non-AF* keliru terklasifikasi sebagai *AF*. Penyebab paling dominan dari masalah ini adalah ketimpangan jumlah data uji yang sangat ekstrem antara sampel *non-AF* dan *AF* (rasio sekitar 12:1), sehingga kesalahan kecil pada persentase prediksi kelas mayoritas berdampak sangat besar pada akumulasi angka *False Positive*. Kemudian, pengujian hanya mengandalkan *input* tunggal berupa sinyal PPG tanpa bantuan sensor *Inertial Measurement Unit* (IMU). Integrasi sensor IMU sengaja tidak diterapkan karena eksperimen awal menunjukkan peningkatan performa yang tidak signifikan, sekaligus untuk mempertahankan fleksibilitas dan kompatibilitas pengujian model pada dataset publik lain yang umumnya tidak menyediakan variabel sinyal IMU.

6. Deployment

6.1 Standard Metric Summary

Untuk memberikan gambaran teknis mengenai spesifikasi implementasi model pada target *hardware*, rincian metrik standarnya dirangkum pada tabel di bawah ini.

Tabel 3 Referensi Workload NPU

Sensor	Model Arch	Input Shape	Params	MAC	Flash	SRAM	Cycle	Accuracy	Quantization
PPG	1D-CNN	1000, 1	4,088,578	16,628,484 MACs/batch	3533.58 KiB	118.83 KiB	3,567,061	68%	INT8

6.2 Deployment Notes

Proses *deployment* model diawali dengan tahap kuantisasi *Post-Training Quantization* (PTQ) berbasis TensorFlow Lite untuk mengonversi seluruh bobot dan aktivasi model dari *floating-point* 32-bit menjadi bilangan bulat 8-bit (INT8) menggunakan sampel representatif dari data latih. Model .tflite INT8 kemudian di-*compile* menggunakan Arm Vela Compiler dengan mengkonfigurasi target akselerator Ethos-U55 berkapasitas 64 MACs/siklus, frekuensi *clock* 500 MHz, serta mode memori *Shared SRAM*. Hasil kompilasi Vela menghasilkan *file* biner yang dioptimasi khusus untuk eksekusi pada NPU Ethos-U55.

Dari sisi pemetaan operator, kompilator Vela berhasil melakukan eksekusi penuh pada NPU dengan tingkat utilisasi *NPU operators* mencapai 100% (34 operator NPU) dan 0% operator yang *fallback* ke CPU. Saat dijalankan pada *runtime* TensorFlow Lite for Microcontrollers (TFLM), 19 operator asli grafik model digabungkan dan dibungkus ke dalam satu operator kustom tunggal bernama *ethos-u*. Hal ini memastikan seluruh beban kalkulasi perkalian matriks dikerjakan langsung oleh NPU tanpa intervensi prosesor utama.

Pengalokasian memori terbagi menjadi dua bagian utama, yaitu memori Flash dan SRAM. Model Vela yang dikompilasi membutuhkan ruang simpan Flash sebesar 3533.58 KiB (~3.45 MB), yang ditempatkan pada memori QSPI Flash eksternal pada *offset* 0xB7B000 dan diakses oleh mikrokontroler melalui pemetaan memori (*memory mapping*) virtual di alamat 0x3AB7B000. Sementara itu, estimasi total SRAM yang dibutuhkan oleh Vela adalah 118.83 KiB, dengan alokasi *Tensor Arena* yang diklaim oleh *allocator* TFLM saat *runtime* sebesar 122.132 bytes (~119.2 KiB).

Pengukuran *latency* dan kinerja siklus dievaluasi menggunakan *Performance Monitoring Unit* (PMU) pada sistem simulasi Corstone-300 / chip Himax HX6538. Hasil profil eksekusi mencatat total kebutuhan siklus sebesar 3.568.050 siklus, yang terdiri dari 3.567.061 siklus aktif NPU dan 989 siklus *idle*. Pada frekuensi kerja NPU sebesar 500 MHz, latensi inferensi *on-device* untuk memproses satu segmen data PPG berdurasi 10 detik adalah sekitar 7,14 milidetik.

Alur pemantauan *real-time* direalisasikan pada *board* fisik Grove Vision AI V2. Sinyal mentah dibaca dari sensor MAX30102 via antarmuka I2C, diproses melalui filter *biquad* dan normalisasi *Z-score* pada *firmware* C, lalu dimasukkan ke dalam *Tensor Arena*. *Driver* Ethos-U selanjutnya mengeksekusi inferensi pada NPU dan mengirimkan hasil prediksi kelas beserta skor keluaran melalui komunikasi serial UART/picocom pada *baudrate* 921600.

7. Conclusion and Challenges

Proyek ini berhasil membuktikan bahwa alur *deployment* model 1D-CNN untuk deteksi Atrial Fibrilasi pada NPU Ethos-U55 dapat mengeksekusi inferensi penuh secara *on-device* dengan latensi sangat rendah (~7,14 ms) serta penurunan performa akibat kuantisasi INT8 yang kecil (*F1-score* kelas AF hanya turun 0,02 dibanding *baseline*). Kendala utama sistem terletak pada presisi kelas AF yang masih rendah (0,12) akibat tingginya angka *False Positive*, yang dipicu oleh ketimpangan rasio sampel data serta kerentanan sinyal PPG tunggal terhadap distorsi.